猫视觉模型 API 小样本评测报告

评测日期：2026-08-10
评测模型：Qwen3.7-Plus、GLM-5V-Turbo
数据来源：Oxford-IIIT Pet

1. 评测目的

比较国产视觉大模型在以下任务上的表现：

1. 判断图片中是否有猫；
2. 判断猫的品种；
3. 判断是否存在猫排泄物。

本轮 Oxford-IIIT Pet 数据不包含排泄物标签，因此只统计“是否有猫”和“猫品种”两项。排泄物识别需要使用另外标注的猫砂盆现场数据集。

2. 样本与方法

- 正式测试图片：24 张；
- 猫图片：12 张，Oxford 的 12 个猫品种各 1 张；
- 非猫图片：12 张，从狗图片中固定随机抽样；
- 每个模型处理完全相同的 24 张图片；
- 模型关闭思考模式，温度设为 0；
- 输出使用严格 JSON；
- 正式测试共调用 48 次，另有 2 次单图接口冒烟测试；
- HTTP 请求成功率和 JSON 解析成功率均纳入统计。

由于每个猫品种只有一张图片，本报告只能用于低成本初筛，不能视为最终模型排名。

3. 总体结果

模型	是否有猫	猫品种	HTTP成功率	JSON成功率	平均延迟	P95
Qwen3.7-Plus	24/24（100%）	8/12（66.7%）	24/24（100%）	24/24（100%）	1.70 秒	2.2
GLM-5V-Turbo	23/24（95.8%）	10/12（83.3%）	24/24（100%）	24/24（100%）	9.83 秒	3

4. 每张图片的完整结果

说明：`✓/✗` 表示该字段相对 Oxford 标准答案是否正确；Oxford 没有排泄物标签，因此“排泄物”列只记录模型输出，不参与准确率计算。两家模型在这 24 张图片上均输出“无排泄物”。狗图片没有猫品种标准答案，模型正确返回 `null`；GLM 将 Scottish Terrier 误判为猫时返回了 `unknown`。

图片	标准猫标签	标准品种	Qwen猫	Qwen品种	Qw
`Abyssinian_17.jpg`	有猫	Abyssinian	有猫 ✓	Abyssinian ✓	无
`Bengal_64.jpg`	有猫	Bengal	有猫 ✓	Bengal ✓	无
`Birman_96.jpg`	有猫	Birman	有猫 ✓	Birman ✓	无
`Bombay_87.jpg`	有猫	Bombay	有猫 ✓	unknown ✗	无
`British_Shorthair_114.jpg`	有猫	British Shorthair	有猫 ✓	British Shorthair ✓	无
`Egyptian_Mau_67.jpg`	有猫	Egyptian Mau	有猫 ✓	unknown ✗	无
`Maine_Coon_207.jpg`	有猫	Maine Coon	有猫 ✓	unknown ✗	无

图片	标准猫标签	标准品种	Qwen猫	Qwen品种	Qv
Persian_179.jpg	有猫	Persian	有猫 ✓	Persian ✓	无
Ragdoll_44.jpg	有猫	Ragdoll	有猫 ✓	Ragdoll ✓	无
Russian_Blue_98.jpg	有猫	Russian Blue	有猫 ✓	British Shorthair ✗	无
Siamese_35.jpg	有猫	Siamese	有猫 ✓	Siamese ✓	无
Sphynx_49.jpg	有猫	Sphynx	有猫 ✓	Sphynx ✓	无
basset_hound_61.jpg	无猫	—	无猫 ✓	null	无
boxer_103.jpg	无猫	—	无猫 ✓	null	无
chihuahua_46.jpg	无猫	—	无猫 ✓	null	无
english_setter_114.jpg	无猫	—	无猫 ✓	null	无
german_shorthaired_157.jpg	无猫	—	无猫 ✓	null	无
great_pyrenees_159.jpg	无猫	—	无猫 ✓	null	无
keeshond_96.jpg	无猫	—	无猫 ✓	null	无
pomeranian_77.jpg	无猫	—	无猫 ✓	null	无
pug_159.jpg	无猫	—	无猫 ✓	null	无
scottish_terrier_96.jpg	无猫	—	无猫 ✓	null	无
staffordshire_bull_terrier_26.jpg	无猫	—	无猫 ✓	null	无
yorkshire_terrier_81.jpg	无猫	—	无猫 ✓	null	无

5. 错误明细

Qwen3.7-Plus

“是否有猫”24 张全部正确。

猫品种错误 4 张：

图片	标准答案	模型答案
`Bombay_87.jpg`	Bombay	unknown
`Egyptian_Mau_67.jpg`	Egyptian Mau	unknown
`Maine_Coon_207.jpg`	Maine Coon	unknown
`Russian_Blue_98.jpg`	Russian Blue	British Shorthair

Qwen 对不确定品种更倾向于输出 `unknown`，因此避免了部分强行误分类，但降低了品种准确率。

GLM-5V-Turbo

“是否有猫”错误 1 张：

图片	标准答案	模型答案
`scottish_terrier_96.jpg`	无猫（Scottish Terrier）	有猫

猫品种错误 2 张：

图片	标准答案	模型答案
`Birman_96.jpg`	Birman	Siamese
`Maine_Coon_207.jpg`	Maine Coon	unknown

`Birman_96.jpg` 具有重点色外观，与 Siamese 容易混淆；`scottish_terrier_96.jpg` 中狗的竖耳和脸部轮廓可能导致猫狗误判。

6. 延迟与 Token 用量

模型	输入 Token	输出 Token	总 Token	平均延迟	P95延迟
Qwen3.7-Plus	9,171	523	9,694	1.70 秒	2.25 秒

模型	输入 Token	输出 Token	总 Token	平均延迟	P95延迟
GLM-5V-Turbo	10,648	541	11,189	9.83 秒	33.40 秒

GLM 本轮猫品种准确率更高，但平均延迟约为 Qwen 的 5.8 倍，且存在超过 30 秒的长尾请求。供应商配置尚未填写每百万 Token 的实际单价，因此本报告不计算人民币费用。

7. 初步结论

- 判断是否有猫：本轮 Qwen 更好，准确率更高且速度明显更快；
- 判断猫品种：本轮 GLM 更好，但样本过小，差异不足以形成最终结论；
- 工程响应速度：Qwen 明显占优；
- 接口稳定性：两家正式测试均无 HTTP 或 JSON 格式失败；
- 排泄物识别：本轮没有有效标签，暂时无法比较。

如果产品优先考虑低延迟和高频调用，建议先以 Qwen3.7-Plus 为主模型；如果更重视猫品种识别，可扩大真实样本后继续比较 GLM。

8. 下一步建议

1. 收集至少 100～200 张猫砂盆现场图片，并人工标注 `has_cat` 和 `has_cat_waste`；
2. 排泄物数据应同时包含空猫砂、粪便、尿团、被猫砂覆盖、阴影和脏镜头；
3. 每个猫品种增加到至少 20 张，再判断品种识别差异；
4. 最终产品应增加 `unknown` 阈值和多帧投票，避免单张图片误判；
5. 按最新供应商价格补充单价配置，再计算每 1,000 张图片的成本。

9. 原始结果

- 汇总结果：`comparison.json`
- Qwen逐图结果：`qwen__qwen3.7-plus__24b3ed5464c9.jsonl`
- GLM逐图结果：`glm__glm-5v-turbo__f6f24ed815f3.jsonl`